

pandas 基础

2026 年 5 月 18 日

1 Hands-on data analysis

2 动手学数据分析

更多 DataWhale 课程请访问

2.1 课程编排与服用方法

课程现分为三个单元，大致可以分为：数据基础操作，数据清洗与重构，建模和评估。

1. 第一部分：我们获得一个要分析的数据，我要学会如何加载数据，查看数据，然后学习 Pandas 的一些基础操作，最后开始尝试探索性的数据分析。
2. 第二部分：当我们可以比较熟练的操作数据并认识这个数据之后，我们需要开始数据清洗以及重构，将原始数据变为一个可用好用的数据，为之后放入模型做准备
3. 第三部分：我们根据任务需求不同，要考虑建立什么模型，我们接触流行的 sklearn 库，建立模型。然后一个模型的好坏，我们是需要评估的，之后我们会引入模型评估的一些改变和实现。

服用方法 我们的代码都是 jupyter 形式，每个部分的课程都分为课程和答案两个部分。学习期间，在课程代码中，完成所有的学习，自己查找资料，自己完成里面的代码操作，思考部分以及心得。关于答案部分，大家可以参考，但是由于数据分析本身是开放的，所以答案也是开放式的，更多希望大家可以有自己理解和答案。

2.2 写在最前面

这门课程的主要目的是通过真实的数据，以实战的方式了解数据分析的流程和熟悉数据分析 Python 的基本操作。

知道了课程的目的之后，我们接下来我们要正式的开始数据分析的实战教学，完成 kaggle 上 [泰坦尼克的任务]

(<https://www.kaggle.com/c/titanic/overview>)，实战数据分析全流程。这里有两份资料需要大家准备：

图书《Python for Data Analysis》第六章和 baidu.com & google.com（善用搜索引擎）

3 Pandas 基础

3.1 1. 知道你的数据叫什么

任务一：Pandas 中有两个数据类型 DataFrame 和 Series，通过查找简单了解他们。

```
[1]: import numpy as np
import pandas as pd
```

```
[2]: sdata = {'Ohio': 35000, 'Texas': 71000, 'Oregon': 16000, 'Utah': 5000}
example_1 = pd.Series(sdata)
example_1
```

```
[2]: Ohio      35000
Texas      71000
Oregon     16000
Utah        5000
dtype: int64
```

```
[3]: data = {'state': ['Ohio', 'Ohio', 'Ohio', 'Nevada', 'Nevada', 'Nevada'],
            'year': [2000, 2001, 2002, 2001, 2002, 2003], 'pop': [1.5, 1.7, 3.6, 2.
→4, 2.9, 3.2]}
example_2 = pd.DataFrame(data)
example_2
```

```
[3]:   state  year  pop
0   Ohio  2000  1.5
1   Ohio  2001  1.7
2   Ohio  2002  3.6
3 Nevada  2001  2.4
4 Nevada  2002  2.9
```

5 Nevada 2003 3.2

任务二：载入 “train.csv” 文件

```
[4]: df = pd.read_csv('/home/jovyan/work/datasets/6645a647c4db0a94029f0bf5-momodel/
↳dataset/train.csv')
df.head(3)
```

```
[4]: PassengerId  Survived  Pclass  \
0             1         0         3
1             2         1         1
2             3         1         3

                                     Name    Sex  Age  SibSp  \
0                                Braund, Mr. Owen Harris    male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                                Heikkinen, Miss. Laina  female  26.0      0

   Parch      Ticket    Fare Cabin Embarked
0      0   A/5 21171    7.2500   NaN        S
1      0   PC 17599   71.2833   C85        C
2      0  STON/O2. 3101282    7.9250   NaN        S
```

任务三：查看 DataFrame 数据的每列的名称

```
[5]: df.columns
```

```
[5]: Index(['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age', 'SibSp',
          'Parch', 'Ticket', 'Fare', 'Cabin', 'Embarked'],
          dtype='object')
```

任务四：查看 “Cabin” 这列的所有值:

```
[6]: df['Cabin'].head(3)
```

```
[6]: 0    NaN
     1    C85
     2    NaN
     Name: Cabin, dtype: object
```

```
[7]: df.Cabin.head(3)
```

```
[7]: 0    NaN
      1    C85
      2    NaN
      Name: Cabin, dtype: object
```

任务五：加载文件 “test_1.csv”，然后对比 “train.csv”，看看有哪些多出的列，然后将多出的列删除经过我们的观察发现一个测试集 test_1.csv 有一列是多余的，我们需要将这个多余的列删去

```
[8]: test_1 = pd.read_csv('/home/jovyan/work/datasets/
↳6645a647c4db0a94029f0bf5-momodel/dataset/test_1.csv')
test_1.head(3)
```

```
[8]:      Unnamed: 0  PassengerId  Survived  Pclass  \
0              0              1           0        3
1              1              2           1        1
2              2              3           1        3

                                     Name      Sex  Age  SibSp  \
0                        Braund, Mr. Owen Harris   male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  38.0      1
2                        Heikkinen, Miss. Laina  female  26.0      0

      Parch      Ticket    Fare Cabin Embarked    a
0         0         A/5 21171   7.2500   NaN        S  100
1         0         PC 17599  71.2833   C85        C  100
2         0  STON/O2. 3101282   7.9250   NaN        S  100
```

```
[9]: # 删除多余的列
del test_1['a']
test_1.head(3)
```

```
[9]:      Unnamed: 0  PassengerId  Survived  Pclass  \
0              0              1           0        3
1              1              2           1        1
2              2              3           1        3
```

	Name	Sex	Age	SibSp	\
0	Braund, Mr. Owen Harris	male	22.0	1	
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	
2	Heikkinen, Miss. Laina	female	26.0	0	

	Parch	Ticket	Fare	Cabin	Embarked
0	0	A/5 21171	7.2500	NaN	S
1	0	PC 17599	71.2833	C85	C
2	0	STON/O2. 3101282	7.9250	NaN	S

【思考】 还有其他的删除多余的列的方式吗？

【思考回答】 除了使用 `drop()` 方法之外，还可以使用 `del` 关键字、`pop()` 方法以及使用布尔索引来选择需要保留的列。

任务六： 将 ['PassengerId','Name','Age','Ticket'] 这几个列元素隐藏，只观察其他几个列元素

```
[10]: df.drop(['PassengerId', 'Name', 'Age', 'Ticket'], axis=1).head(3)
```

```
[10]:   Survived  Pclass    Sex  SibSp  Parch    Fare  Cabin  Embarked
0         0      3   male     1     0   7.2500   NaN        S
1         1      1  female     1     0  71.2833   C85        C
2         1      3  female     0     0   7.9250   NaN        S
```

【思考】 对比任务五和任务六，是不是使用了不一样的方法（函数），如果使用一样的函数如何完成上面的不同的要求呢？

【思考回答】 如果想要完全的删除你的数据结构，使用 `inplace=True`，因为使用 `inplace` 就将原数据覆盖了，所以这里没有用

```
[11]: # 思考回答
df.head(3)
```

```
[11]:   PassengerId  Survived  Pclass  \
0             1         0       3
1             2         1       1
2             3         1       3
```

Name	Sex	Age	SibSp	\
------	-----	-----	-------	---

```

0          Braund, Mr. Owen Harris    male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th... female  38.0      1
2          Heikkinen, Miss. Laina  female  26.0      0

```

```

      Parch      Ticket    Fare Cabin Embarked
0         0   A/5 21171   7.2500   NaN        S
1         0    PC 17599  71.2833   C85        C
2         0 STON/O2. 3101282   7.9250   NaN        S

```

3.2 2. 筛选的逻辑

表格数据中，最重要的一个功能就是要具有可筛选的能力，选出我所需要的信息，丢弃无用的信息。

下面我们还是用实战来学习 Pandas 这个功能。

任务一：我们以 “Age” 为筛选条件，显示年龄在 10 岁以下的乘客信息。

```
[12]: df[df["Age"]<10].head(3)
```

```

[12]:   PassengerId  Survived  Pclass                    Name  Sex \
7         8         0         3  Palsson, Master. Gosta Leonard  male
10        11         1         3  Sandstrom, Miss. Marguerite Rut  female
16        17         0         3                Rice, Master. Eugene  male

```

```

      Age  SibSp  Parch      Ticket    Fare Cabin Embarked
7    2.0     3      1   349909  21.075   NaN        S
10   4.0     1      1  PP 9549  16.700    G6        S
16   2.0     4      1  382652  29.125   NaN        Q

```

任务二：以 “Age” 为条件，将年龄在 10 岁以上和 50 岁以下的乘客信息显示出来，并将这个数据命名为 midage

```
[13]: midage = df[(df["Age"]>10) & (df["Age"]<50)]
midage.head(3)
```

```

[13]:   PassengerId  Survived  Pclass \
0         1         0         3
1         2         1         1

```

```
2          3          1          3
```

	Name	Sex	Age	SibSp	\
0	Braund, Mr. Owen Harris	male	22.0	1	
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	
2	Heikkinen, Miss. Laina	female	26.0	0	

	Parch	Ticket	Fare	Cabin	Embarked
0	0	A/5 21171	7.2500	NaN	S
1	0	PC 17599	71.2833	C85	C
2	0	STON/O2. 3101282	7.9250	NaN	S

【提示】了解 Pandas 的条件筛选方式以及如何使用交集和并集操作

任务三：将 midage 的数据中第 100 行的 “Pclass” 和 “Sex” 的数据显示出来

```
[14]: midage = midage.reset_index(drop=True)
midage.head(3)
```

```
[14]: PassengerId  Survived  Pclass  \
0           1         0         3
1           2         1         1
2           3         1         3
```

	Name	Sex	Age	SibSp	\
0	Braund, Mr. Owen Harris	male	22.0	1	
1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	
2	Heikkinen, Miss. Laina	female	26.0	0	

	Parch	Ticket	Fare	Cabin	Embarked
0	0	A/5 21171	7.2500	NaN	S
1	0	PC 17599	71.2833	C85	C
2	0	STON/O2. 3101282	7.9250	NaN	S

【思考】这个 reset_index() 函数的作用是什么？如果不用这个函数，下面的任务会出现什么情况？

```
[15]: midage.loc[[100],['Pclass','Sex']]
```

```
[15]:      Pclass  Sex
      100      2  male
```

任务四：使用 loc 方法将 midage 的数据中第 100, 105, 108 行的 “Pclass”, “Name” 和 “Sex” 的数据显示出来

```
[16]: midage.loc[[100,105,108],['Pclass','Name','Sex']]
```

```
[16]:      Pclass      Name  Sex
      100      2  Byles, Rev. Thomas Roussel Davids  male
      105      3      Cribb, Mr. John Hatfield  male
      108      3      Calic, Mr. Jovo  male
```

任务五：使用 iloc 方法将 midage 的数据中第 100, 105, 108 行的 “Pclass”, “Name” 和 “Sex” 的数据显示出来

```
[17]: midage.iloc[[100,105,108],[2,3,4]]
```

```
[17]:      Pclass      Name  Sex
      100      2  Byles, Rev. Thomas Roussel Davids  male
      105      3      Cribb, Mr. John Hatfield  male
      108      3      Calic, Mr. Jovo  male
```

【思考】对比 iloc 和 loc 的异同