

数据载入及初步观察

2026 年 5 月 19 日

1 数据载入及初步观察

1.1 1. 载入数据

数据集下载 <https://www.kaggle.com/c/titanic/overview>

任务一：导入 NumPy 和 Pandas

```
[3]: import numpy as np
import pandas as pd
```

【提示】如果加载失败，学会如何在你的 Python 环境下安装 NumPy 和 Pandas 这两个库

任务二：载入数据

```
[4]: df = pd.read_csv('/home/jovyan/work/datasets/6645a647c4db0a94029f0bf5-momodel/
↳dataset/train.csv')
df.head(3)
```

```
[4]: PassengerId  Survived  Pclass  \
0             1         0         3
1             2         1         1
2             3         1         3
```

```
                                Name    Sex  Age  SibSp  \
0                Braund, Mr. Owen Harris  male  22.0      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th... female  38.0      1
2                Heikkinen, Miss. Laina  female  26.0      0
```

```
Parch          Ticket    Fare Cabin Embarked
```

0	0	A/5 21171	7.2500	NaN	S
1	0	PC 17599	71.2833	C85	C
2	0	STON/O2. 3101282	7.9250	NaN	S

任务三：每 1000 行为一个数据模块，逐块读取

```
[5]: chunker = pd.read_csv('/home/jovyan/work/datasets/
↳6645a647c4db0a94029f0bf5-momodel/dataset/train.csv', chunksize=1000)
```

【思考】什么是逐块读取？为什么要逐块读取呢？

【提示】chunker (数据块) 是什么类型？用 for 循环打印出来出处具体的样子是什么？

逐块读取是一种处理数据的方法，特别是在处理大型文件或数据流时。

它的工作原理是将数据分成较小的块或段，然后一次处理一个块，而不是一次性加载整个文件或数据流。

逐块读取的主要优点是：

1. 内存效率：逐块读取可以有效地处理大型文件，因为它不需要一次性将整个文件加载到内存中。这对于处理大型文件或数据流特别有用，因为这些文件可能会超过可用内存的大小。
2. 性能优化：逐块读取可以提高数据处理的速度，因为它允许程序在读取下一个数据块的同时处理当前的数据块。
3. 实时处理：对于实时数据流，如网络流或设备输入，逐块读取可以实现实时或近实时的数据处理。

任务四：将表头改成中文，索引改为乘客 ID

PassengerId	=>	乘客ID
Survived	=>	是否幸存
Pclass	=>	乘客等级(1/2/3等舱位)
Name	=>	乘客姓名
Sex	=>	性别
Age	=>	年龄
SibSp	=>	堂兄弟/妹个数
Parch	=>	父母与小孩个数
Ticket	=>	船票信息
Fare	=>	票价
Cabin	=>	客舱

Embarked => 登船港口

```
[6]: df = pd.read_csv('/home/jovyan/work/datasets/6645a647c4db0a94029f0bf5-momodel/
↳ dataset/train.csv', names=['乘客 ID','是否幸存','仓位等级','姓名','性别','年
龄','兄弟姐妹个数','父母子女个数','船票信息','票价','客舱','登船港
口'], index_col='乘客 ID', header=0)
df.head()
```

```
[6]:      是否幸存  仓位等级      姓名
↳ 性别 \
乘客 ID
1      0      3      Braund, Mr. Owen Harris    male
2      1      1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female
3      1      3      Heikkinen, Miss. Laina    female
4      1      1  Futrelle, Mrs. Jacques Heath (Lily May Peel)  female
5      0      3      Allen, Mr. William Henry    male

      年龄  兄弟姐妹个数  父母子女个数      船票信息      票价      客舱
↳ 登船港口
乘客 ID
1      22.0      1      0      A/5 21171      7.2500      NaN      S
2      38.0      1      0      PC 17599      71.2833      C85      C
3      26.0      0      0  STON/O2. 3101282      7.9250      NaN      S
4      35.0      1      0      113803      53.1000      C123      S
5      35.0      0      0      373450      8.0500      NaN      S
```

【思考】所谓将表头改为中文其中一个思路是：将英文列名表头替换成中文。还有其他的方法吗？

1.2 2. 初步观察

导入数据后，你可能要对数据的整体结构和样例进行概览，比如说，数据大小、有多少列，各列都是什么格式的，是否包含 null 等

任务一：查看数据的基本信息

```
[7]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

Int64Index: 891 entries, 1 to 891

Data columns (total 11 columns):

#	Column	Non-Null Count	Dtype
0	是否幸存	891 non-null	int64
1	仓位等级	891 non-null	int64
2	姓名	891 non-null	object
3	性别	891 non-null	object
4	年龄	714 non-null	float64
5	兄弟姐妹个数	891 non-null	int64
6	父母子女个数	891 non-null	int64
7	船票信息	891 non-null	object
8	票价	891 non-null	float64
9	客舱	204 non-null	object
10	登船港口	889 non-null	object

dtypes: float64(2), int64(4), object(5)

memory usage: 83.5+ KB

任务二：观察表格前 10 行的数据和后 15 行的数据

```
[8]: df.head(10)
```

```
[8]:
```

	是否幸存	仓位等级	姓名	性别	年龄	兄弟姐妹个数	父母子女个数	船票信息	票价	客舱	登船港口
1	0	3	Braund, Mr. Owen Harris	male							
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female							
3	1	3	Heikkinen, Miss. Laina	female							
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female							
5	0	3	Allen, Mr. William Henry	male							
6	0	3	Moran, Mr. James	male							
7	0	1	McCarthy, Mr. Timothy J	male							
8	0	3	Palsson, Master. Gosta Leonard	male							
9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female							
10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female							

乘客 ID							
1	22.0	1	0	A/5 21171	7.2500	NaN	S
2	38.0	1	0	PC 17599	71.2833	C85	C
3	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
4	35.0	1	0	113803	53.1000	C123	S
5	35.0	0	0	373450	8.0500	NaN	S
6	NaN	0	0	330877	8.4583	NaN	Q
7	54.0	0	0	17463	51.8625	E46	S
8	2.0	3	1	349909	21.0750	NaN	S
9	27.0	0	2	347742	11.1333	NaN	S
10	14.0	1	0	237736	30.0708	NaN	C

```
[9]: df.tail(15)
```

[9]:			是否幸存	仓位等级	姓名		性
别	年龄	\					
乘客 ID							
877	0	3	Gustafsson, Mr. Alfred Ossian		male	20.0	
878	0	3	Petroff, Mr. Nedelio		male	19.0	
879	0	3	Laleff, Mr. Kristo		male	NaN	
880	1	1	Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)		female	56.0	
881	1	2	Shelley, Mrs. William (Imanita Parrish Hall)		female	25.0	
882	0	3	Markun, Mr. Johann		male	33.0	
883	0	3	Dahlberg, Miss. Gerda Ulrika		female	22.0	
884	0	2	Banfield, Mr. Frederick James		male	28.0	
885	0	3	Sutehall, Mr. Henry Jr		male	25.0	
886	0	3	Rice, Mrs. William (Margaret Norton)		female	39.0	
887	0	2	Montvila, Rev. Juozas		male	27.0	
888	1	1	Graham, Miss. Margaret Edith		female	19.0	
889	0	3	Johnston, Miss. Catherine Helen "Carrie"		female	NaN	
890	1	1	Behr, Mr. Karl Howell		male	26.0	
891	0	3	Dooley, Mr. Patrick		male	32.0	
兄弟姐妹个数		父母子女个数	船票信息		票价	客舱 登船港口	
乘客 ID							
877	0	0	7534	9.8458	NaN	S	

878	0	0		349212	7.8958	NaN	S
879	0	0		349217	7.8958	NaN	S
880	0	1		11767	83.1583	C50	C
881	0	1		230433	26.0000	NaN	S
882	0	0		349257	7.8958	NaN	S
883	0	0		7552	10.5167	NaN	S
884	0	0	C.A./SOTON	34068	10.5000	NaN	S
885	0	0	SOTON/OQ	392076	7.0500	NaN	S
886	0	5		382652	29.1250	NaN	Q
887	0	0		211536	13.0000	NaN	S
888	0	0		112053	30.0000	B42	S
889	1	2	W./C.	6607	23.4500	NaN	S
890	0	0		111369	30.0000	C148	C
891	0	0		370376	7.7500	NaN	Q

任务三：判断数据是否为空，为空的地方返回 True，其余地方返回 False

```
[10]: df.isnull().head()
```

[10]: 是否幸存 仓位等级 姓名 性别 年龄 兄弟姐妹个数 父母子女个数

→ 船票信息 票价 客舱 \

乘客 ID

1	False	False	False	False	False	False	False	False	False	True
2	False	False	False	False	False	False	False	False	False	False
3	False	False	False	False	False	False	False	False	False	True
4	False	False	False	False	False	False	False	False	False	False
5	False	False	False	False	False	False	False	False	False	True

登船港口

乘客 ID

1	False
2	False
3	False
4	False
5	False

【总结】上面的操作都是数据分析中对于数据本身的观察

【思考】对于一个数据，还可以从哪些方面来观察？找找答案，这个将对下面的数据分析有很大的帮助

1.3 3. 保存数据

将你加载并做出改变的数据，在工作目录下保存为一个新文件 train_chinese.csv

```
[11]: # 注意：不同的操作系统保存下来可能会有乱码。大家可以加入`encoding='GBK'` 或者 `
      encoding = 'utf-8'
      df.to_csv('/home/jovyan/work/results/train_chinese.csv')
```

【总结】数据的加载以及入门，接下来就要接触数据本身的运算，我们将主要掌握 NumPy 和 Pandas 在工作和项目场景的运用。

1.4 4. 探索性数据分析

```
[12]: # 载入之前保存的 train_chinese.csv 数据，关于泰坦尼克号的任务，我们就使用这个数据
      text = pd.read_csv('/home/jovyan/work/datasets/6645a647c4db0a94029f0bf5-momodel/
      ↳dataset/train_chinese.csv')
      text.head()
```

```
[12]: 乘客 ID  是否幸存  仓位等级  姓
      名 \
0      1      0      3      Braund, Mr. Owen Harris
1      2      1      1  Cumings, Mrs. John Bradley (Florence Briggs Th...
2      3      1      3      Heikkinen, Miss. Laina
3      4      1      1  Futrelle, Mrs. Jacques Heath (Lily May Peel)
4      5      0      3      Allen, Mr. William Henry
```

```
      性别  年龄  兄弟姐妹个数  父母子女个数  船票信息  票价
↳ 客舱 登船港口
0  male  22.0      1      0      A/5 21171  7.2500  NaN  S
1  female  38.0      1      0      PC 17599  71.2833  C85  C
2  female  26.0      0      0  STON/O2. 3101282  7.9250  NaN  S
3  female  35.0      1      0      113803  53.1000  C123  S
4  male  35.0      0      0      373450  8.0500  NaN  S
```

1.4.1 4.1 了解数据

教材《Python for Data Analysis》第五章

1.4.2 4.2 对泰坦尼克号数据 (trian.csv) 按票价和年龄两列进行综合排序 (降序排列)，从数据中你能发现什么

```
[ ]: '''
    在开始我们已经导入了 train_chinese.csv 数据，而且前面我们也学习了导入数据过程，根据
    上面学习，我们直接对目标列进行排序即可
    head(20) : 读取前 20 条数据
    '''

text.sort_values(by=['票价', '年龄'], ascending=False).head(3)
```

[]:	乘客 ID	是否幸存	仓位等级	姓名	性别
	年龄 \				
679	680	1	1	Cardeza, Mr. Thomas Drake Martinez	male 36.0
258	259	1	1	Ward, Miss. Anna	female 35.0
737	738	1	1	Lesurer, Mr. Gustave J	male 35.0

	兄弟姐妹个数	父母子女个数	船票信息	票价	客舱	登船港口
679	0	1	PC 17755 512.3292 B51 B53 B55	C		
258	0	0	PC 17755 512.3292	NaN	C	
737	0	0	PC 17755 512.3292	B101	C	

【思考】排序后，如果我们仅仅关注年龄和票价两列。

根据常识我知道发现票价越高的应该客舱越好，所以我们会明显看出，票价前 20 的乘客中存活的有 14 人，这是相当高的一个比例。

那么我们后面是不是可以进一步分析一下票价和存活、年龄和存活之间的关系呢？

当你开始发现数据之间的关系了，数据分析就开始了。当然，这只是我的想法，你还可以有更多想法，欢迎写在你的学习笔记中。

1.4.3 4.3 过泰坦尼克号数据如何计算出在船上最大的家族有多少人？

```
[14]: '''  
还是用之前导入的 chinese_train.csv 如果我们想看看在船上，最大的家族有多少人（‘兄弟姐妹个数’ + ‘父母子女个数’），我们该怎么做呢？  
'''  
  
max(text['兄弟姐妹个数'] + text['父母子女个数'])
```

[14]: 10

是的，如上，很简单，我们只需找出兄弟姐妹个数和父母子女个数之和最大的数就行，先让这两列相加返回一个 DataFrame，然后用 max 函数求出最大值。

当然你还可以想出很多方法和思考角度，欢迎你来说出你的看法。

1.4.4 4.4 分别看看泰坦尼克号数据集中票价、父母子女这列数据的基本统计数据，你能发现什么？

```
[15]: '''  
看看泰坦尼克号数据集中 票价 这列数据的基本统计数据  
'''  
  
text['票价'].describe()
```

```
[15]: count      891.000000  
mean         32.204208  
std          49.693429  
min           0.000000  
25%           7.910400  
50%          14.454200  
75%          31.000000  
max          512.329200  
Name: 票价, dtype: float64
```

【思考】从上面数据我们可以看出，一共有 891 个票价数据，平均值约为：32.20，标准差约为 49.69，说明票价波动特别大。

25% 的人的票价是低于 7.91 的，50% 的人的票价低于 14.45，75% 的人的票价低于 31.00，票价最大值约为 512.33，最小值为 0。

当然，这只是我的想法，你还可以有更多想法，欢迎写在学习笔记中。

```
[16]: '''  
通过上面的例子，我们再看看泰坦尼克号数据集中 父母子女个数 这列数据的基本统计数据，然  
后可以说出你的想法  
'''  
text['父母子女个数'].describe()
```

```
[16]: count      891.000000  
      mean        0.381594  
      std         0.806057  
      min         0.000000  
      25%         0.000000  
      50%         0.000000  
      75%         0.000000  
      max         6.000000  
      Name: 父母子女个数, dtype: float64
```

【总结】 本节中我们通过 Pandas 的一些内置函数对数据进行了初步统计查看，这个过程最重要的不是大家得掌握这些函数，而是看懂从这些函数出来的数据，构建自己的数据分析思维

希望大家学完这一章能对数据有个基本认识，了解自己在做什么，为什么这么做，后面的章节我们将开始对数据进行清洗，进一步分析。